

南昌大学实验报告

学生姓名: <u>丁俊</u> 学 号: <u>8003119100</u> 专业班级: <u>信息安全 193 班</u> 实验类型: □ 验证■ 综合 □ 设计 □ 创新 实验日期: <u>2021.11.18</u> 实验成绩: _____

一、实验项目名称

数据处理

二、实验目的

- 1. 掌握 numpy、pandas 等库的使用
- 2. 掌握数据筛选、数据转换以及时间格式数据的处理
- 3. 掌握缺失值的检测和处理

三、实验任务

参照房屋资料处理和新闻资料处理案例完成以下任务:

资料筛选、资料转换 侦测遗失值和补齐遗失值 处理时间格式数据 重塑资料

四、主要仪器设备及耗材

软件: Anaconda 或者 pycharm 等

五、实验步骤

(请根据实际的操作来填写)

1、访问新浪新闻网页

```
In [158]: import requests
   import re
   from bs4 import BeautifulSoup
   res = requests.get('https://news.sina.com.cn/')
```



2、获取新闻信息详情函数

获取标题 title、内容 content、日期 date、来源 source、关键词 keywords,并返回一个字典。这里已经对一些数据进行了预处理,比如 content,去除一些换行符、回车符等。

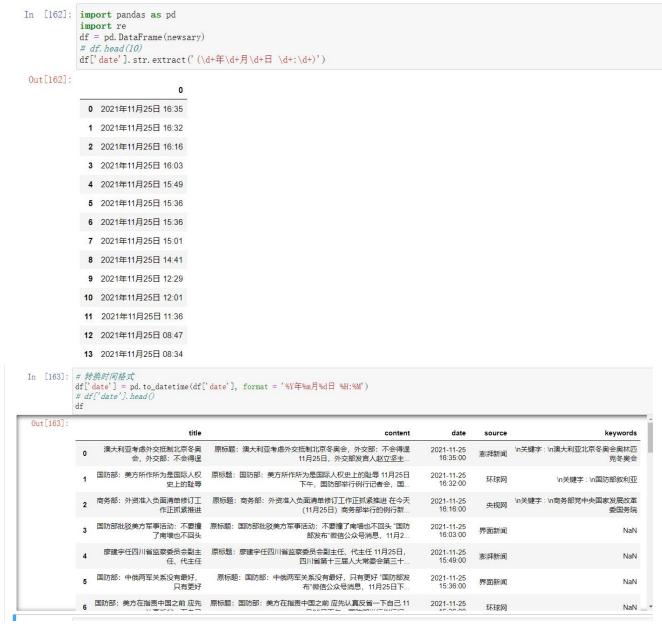
```
In [104]: def getAct(url):
              res = requests. get (ur1)
              res.encoding = 'utf-8'
              bs = BeautifulSoup(res.text, 'lxml')
              actdict = {}
              actdict['title'] = bs.select('.main-title')[0].text
              actdict['content'] = ' '.join(bs.select('.article')[0].text.split())
actdict['date'] = bs.select('span.date')[0].text
actdict['source'] = bs.select('.source')[0].text
              if len(bs.select('.keywords')) > 0:
                  actdict['keywords'] = bs. select('.keywords')[0].text
              return actdict
    . Anth crass- robings intilles creasing N
       <div class="second-title">北京市发改委主任谈绪祥已任市政府党组成员</div>
             class="date-source" data-sudaclick="share_i-0"
         a mref= <u>nttps://mp.weixin.qq.com/s/Wzff2H&M5eoKIY n5HCt</u>Iw" target="_blank
         class="source" data-sudaclick="content media p" rel="nofollow">新京报</a>
       </div>
      <div class="page-tools">...</div>
        ::after
      </div>
   <!-- 面包削 search end -->
   <h1 class="main-title">北京市发改委主任谈绪祥已任市政府党组成员</h1>
   <!-- page-tools start -->
  <stvle type="text/css">...</stvle>
```

```
▼ <div class="article-bottom clearfix" id="article-bottom">
 ▼<div class="keywords" id "keywords" data-wbkey="新冠肺炎,河北,新闻" data-
          content_keywords_p
       -1 关键字
    <a href="http://tags.news.sina.com.cn/新冠肺炎" target="_blank">新冠肺炎</a>
    <a href="http://tags.news.sina.com.cn/河北" target="_blank">河北</a>
  </div>
 <div class="btns">...</div>
  ::after
 </div>
 <!-- 文章关键字 end -->
 <div id="wxFollow"></div>
  <:-- 5|X Start -->
  <!-- 引文 end -->
  <!-- 正文 start -->
 ▼<div class="article" id "article"> == $0
```

3、将新闻的字典信息存入列表中

遍历新闻列表中的每一个 ul,并遍历其中的 li a 链接,并访问该链接的详情信息。

4、处理日期



把日期变为 datetime 格式。

5、处理空值

判断有空值的列,可以看到 keywords 列是有空值的。

```
In [127]: df.isnull().any()

Out[127]: title False content False date False source False keywords True dtype: bool
```

这里我把空值和非空值的行分为两组,进行分别处理,再把两组数据拼接起来,

带空值的行筛选

In [164]: **import** numpy **as** np
df['keywords'].finIlna('誓无')
df1 = df[df['keywords'].isnull()] # 先把空值的行记录下来
df1

Out[164]:

	title	content	date	source	keywords
3	国防部批驳美方军事活动:不要撞了南墙也不 回头	原标题:国防部批驳美方军事活动:不要撞了南墙也不回头 "国防部发布"微信公众号 消息,11月2	2021-11-25 16:03:00	界面新闻	NaN
4	廖建宇任四川省监察委员会副主任、代主任	原标题:廖建宇任四川省监察委员会副主任、代主任 11月25日,四川省第十三届人 大常委会第三十…	2021-11-25 15:49:00	澎湃新闻	NaN
5	国防部:中俄两军关系没有最好,只有更好	原标题:国防部:中俄两军关系没有最好,只有更好 "国防部发布"微信公众号消息, 11月25日下	2021-11-25 15:36:00	界面新闻	NaN
6	国防部:美方在指责中国之前 应先认真反省 一下自己	原标题:国防部:美方在指责中国之前 应先认真反省一下自己 11月25日下午,国防 部举行例行记…	2021-11-25 15:36:00	环球网	NaN
8	处置实验室漏水立功! 5名大学生被中科大奖 励12万元	原标题: 处置实验室漏水立功! 5名大学生被中科大奖励12万元 记者从中国科学技术 大学获悉,11	2021-11-25 14:41:00	央视网	NaN
9	北京市发改委主任谈绪祥已任市政府党组成员	原标题:北京市发改委主任谈绪祥已任市政府党组成员 据微信公号"北京京剧院"11月 24日消息:	2021-11-25 12:29:00	新京报	NaN
10	河北衡水居民拨打12345热线反被训斥 涉事人 员被停职	原标题:衡水高新区关于保利拉菲公馆小区某业主反映物业费问题的情况通报 来源:衡水高新区 对"	2021-11-25 12:01:00	政府网站	NaN
14	我国成功发射试验十一号卫星	原标题:我国成功发射试验十一号卫星北京时间2021年11月25日7时41分,我国在 酒泉卫星	2021-11-25 08:09:00	界面新闻	NaN
23	北京冬残奥会火炬接力将于明年3月2日—4日 举行	原标题:北京冬残奥会火炬接力将于明年3月2日—4日举行今天是北京冬残奥会开幕 倒计时100天	2021-11-24 20:19:00	央视网	NaN
26	印度人也生得少了! 人口或于2060年后下降	原标题:印度人也生得少了!人口或于2060年后下降 据外媒24日报道,印度全国家 庭健康调查最	2021-11-25 16:24:00	红星新闻	NaN
20	俄克麦罗沃州一矿井发生冒烟事故 已致1人死	原标题:俄克麦罗沃州一矿井发生冒烟事故 已致1人死数十人伤 中新网11月25日电	2021-11-25	中国新闻	Maki

非空值行筛选

keywords	source	date	content	title	
\n关键字:\n澳大利亚北京冬奥会奥林匹 克冬奥会	澎湃新闻	2021-11-25 16:35:00	原标题:澳大利亚考虑外交抵制北京冬奥会,外交部:不会得逞 11 月25日,外交部发言人赵立坚主…	澳大利亚考虑外交抵制北京冬奥 会,外交部:不会得逞	0
\n关键字:\n国防部叙利亚	环球网	2021-11-25 16:32:00	原标题:国防部:美方所作所为是国际人权史上的耻辱 11月25日下 午,国防部举行例行记者会,国	国防部:美方所作所为是国际人权 史上的耻辱	1
\n关键字:\n商务部党中央国家发展改革 委国务院	央视网	2021-11-25 16:16:00	原标题:商务部:外资准入负面清单修订工作正抓紧推进在今天 (11月25日) 商务部举行的例行新	商务部:外资准入负面清单修订工 作正抓紧推进	2
\n关键字:\n国防部中美关系	国防部网站	2021-11-25 15:01:00	原标题:国防部:推动中美两军关系健康稳定地向前发展 11月25日 下午,国防部举行例行记者会,	国防部:推动中美两军关系健康稳 定地向前发展	7
\n关键字:\n新冠肺炎	新浪新闻 综合	202 <mark>1-11-25</mark> 11:36:00	原标题:大连发布返校复学预告 来源:半岛晨报 根据全市疫情防控总体形势,如果社会面无新增新冠	大连发布返校复学预告	11
\n关键字:\n新冠肺炎湖南	界面新闻	202 <mark>1</mark> -11-25 08:47:00	原标题:湖南11月24日新增境外输入无症状感染者1例 据湖南卫健 委,2021年11月24日0	湖南11月24日新增境外输入无症状 感染者1例	12
/n关键字:/n新冠肺炎	每日经济 新闻	2021-11-25 08:34:00	原标题:张文宏团队发表最新研究,系中国研究人员首次 据第一财 经报道,11月23日,复旦大学附	张文宏团队发表最新研究 系中国研究人员首次	13
\n关键字:\n新冠肺炎安徽	界面新闻	2021-11-25 08:08:00	原标题:安徽11月24日新增境外输入无症状感染者1例 据安徽卫健 委通报, 2021年11月24	安徽11月24日新增境外输入无症状 感染者1例	15
\n关键字:\n新冠肺炎辽宁	央视网	2021-11-25 08:05:00	原标题:辽宁本土确诊0新增辽宁本轮疫情首次无新增确诊 转发好 消息!加油! 11月24日0时	辽宁本土确诊0新增 本轮疫情首次 无新增确诊	16
\n关键字:\n新冠肺炎北京	新浪新闻 综合	2021-11-25 07:51:00	原标题:疫情发布 北京11月24日无新增新冠肺炎确诊病例 新增2 例境外输入无症状感染者	北京昨日新增2例境外输入无症状 感染者	17
\n关键字:\n新冠肺炎河北	界面新闻	2021-11-25 07:19:00	原标题:河北辛集:全面恢复市域内人员正常出行据"辛集发布"消息,辛集市疫情防控工作总指挥部	河北辛集:全面恢复市域内人员正 常出行	18
\n关键字:\n空间站	央视网	2021-11-24 22:29:00	原标题:天宫TV上新!直击"80后"男航天员的在轨日常"我是03, 我下次出舱,感觉良好!"	天宫TV上新! 直击"80后"男航天员 的在轨日常	19
\n关键字:\n农业农村部	新华网	2021-11-24	原标题: 民生直通年 这次大规模农业种质资源普查,我们收获了	这次大规模农业种质资源普查 我们	20

处理非空值行,把一些符号去掉,保留有用信息和格式

```
: # 处理非空行
df['keywords'] = df['keywords']. map(lambda x:x. split(':')[1]. split())
df
```

	title	content	date	source	keywords
5	大连发布返校复学预告	原标题: 大连发布返校复学预告 来源: 半岛晨报 根据全市疫情防控总 体形势,如果社会面无新增新冠	2021-11-25 11:36:00	新浪新闻综 合	新冠肺炎
6	湖南11月24日新增境外输入无症状感 染者1例	原标题:湖南11月24日新增境外输入无症状感染者1例 据湖南卫健委, 2021年11月24日0	2021- <mark>1</mark> 1-25 08:47:00	界面新闻	新冠肺炎湖南
8	安徽11月24日新增境外输入无症状感 染者1例	原标题:安徽11月24日新增境外输入无症状感染者1例 据安徽卫健委通报, 2021年11月24	2021-11-25 08:08:00	界面新闻	新冠肺炎安徽
9	辽宁本土确诊0新增 本轮疫情首次无 新增确诊	原标题:辽宁本土确诊0新增辽宁本轮疫情首次无新增确诊转发好消息:加油:11月24日0时	2021-11-25 08:05:00	央视网	新冠肺炎辽宁
10	北京昨日新增2例境外输入无症状感 染者	原标题:疫情发布 北京11月24日无新增新冠肺炎确诊病例 新增2例境 外输入无症状感染者	2021-11-25 07:51:00	新浪新闻综 合	新冠肺炎北京
11	河北辛集:全面恢复市域内人员正常 出行	原标题:河北辛集:全面恢复市域内人员正常出行据"辛集发布"消息。 辛集市疫情防控工作总指挥部	2021- <mark>1</mark> 1-25 07:19:00	界面新闻	新冠肺炎河北
12	天宫TV上新! 直击"80后"男航天员的 在轨日常	原标题:天宫TV上新!直击"80后"男航天员的在轨日常"我是03,我下次出舱,感觉良好!"	2021-11-24 22:29:00	央视网	空间站

填充空值

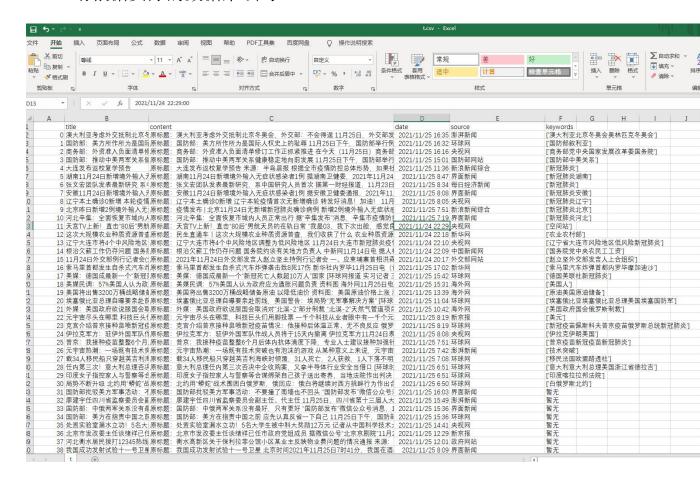
合并数据

保存数据到 csv 文件

```
df. to_csv('t.csv', encoding='utf-8-sig')
```

六、实验数据及处理结果

(请根据实际的数据来填写)



七、思考讨论题或体会或对改进实验的建议

(请根据实际的数据来填写)

如果想做有关于数据处理的实验,需要找到适合的网站,但是现在网站大部分比较完善, 很难找到那种可以锻炼的网页,建议实机演示比较好。

八、参考资料

- [1] 朝乐门 著. Python 编程 从数据分析到数据科学.电子工业出版社.2019.1
- [2] [美] 阿曼多 凡丹戈 (Armando Fandango) 著, 韩波 译. Python 数据分析(第 2 版). 人民邮电出版社.2018.6
- [3] 嵩天,礼欣,黄天羽 著.Python 语言程序设计基础(第2版). 高等教育出版社.2017.2