

南昌大学实验报告

一、实验项目名称

网络爬虫

二、实验目的

- 1. 掌握 web 数据采集技术
- 2. 掌握 Requests 库的使用
- 3. 掌握 web 信息提取技术 Beautiful Soup 库和 re 库等的使用

三、实验任务

参照房天下房价信息搜集案例和猫眼电影数据采集案例完成以下任务:

- 1、采集新闻网站的相关类别信息或豆瓣网站相关栏目信息;
- 2、对相关页面进行内容提取,生成文本集(txt或Excel等形式)

四、主要仪器设备及耗材

软件: Anaconda 或者 pycharm 等

五、实验步骤

第一步:确定采集网站和数据集合

本次实验对 https://movie.douban.com/top250 豆瓣 Top250 电影进行数据提取,如图。



每一页有25项数据,我们要找出每一项电影的电影详情链接、影片中文名、影片外国名、评分、评价数、概况、相关信息等。

以第一步电影"肖申克的救赎"为例,通过 F12 开发者模式查看网页的源代码找出相应信息的标签代码格式,便于爬虫使用正则表达式爬取相关信息。

```
LE III LIEUEUR COURSE SOURCES INCLINION PERIORIMANCE // WILLE F.J W.
              ▼ <div class="hd">
                ▼ <a href="https://movie.douban.com/subject/1292052
                                                          /" class>
                  <span class="title">肖申克的救赎</span> 中文名
                  <span class="title">&nbsp;/&nbsp;The Shawshank Redemption</span>
                  <span class="other">&nbsp;/&nbsp;月黑高飞(港) / 刺激1995(台)</span>
                 <span class="playable">[可播放]</span>
               </div>
              ▼ <div class="bd">
                ▼ ...  == $0
                   " 导演: 弗兰克·德拉邦特 Frank Darabont   主演: 蒂姆·罗宾斯 Tim
                   Robbins /..." 相关信息
                   " 1994 / 美国 / 犯罪 剧情 "
                 ▼ <div class="star">
                  <span class="rating5-t"></span>
                  <span class="rating_num" property="v:average">9.7</span>
                  <span property="v:best" content="10.0"></span>
                  <span>2471383人评价</span> ____ 评价数
                 </div>
                ▼ 
                  <span class="inq">希望让人自由。</span> 概况
               </div>
              </div>
            </div>
```

第二步: 使用代码请求网页内容

模仿浏览器头部向豆瓣请求信息

```
1.#得到指定一个 URL 的网页内容
2.def askURL(url):
     head = {
                           #模拟浏览器头部信息,向豆瓣服务器发送消息
         "User-Agent": "Mozilla / 5.0(Windows NT 10.0; Win64; x64) AppleWebKit
   / 537.36(KHTML, like Gecko) Chrome / 80.0.3987.122 Safari / 537.36"
5.
     }
6.
                           #用户代理,表示告诉豆瓣服务器,我们是什么类型的机器、浏
   览器(本质上是告诉浏览器,我们可以接收什么水平的文件内容)
7.
     html = ""
8.
     try:
9.
         # response = urllib.request.urlopen(request) #实现对目标 url 的访问
          response = requests.get(url,headers=head)
10.
          # html = response.read().decode("utf-8")
11.
12.
          #print(html)
13.
      except requests as e:
          if hasattr(e, "code"): # 对应的属性名
14.
15.
              print(e.code)
```

```
if hasattr(e, "reason"):
16.
17.
                print(e.reason)
18.
        return response.text
```

第三步: 使用正则表达式 re 和 BeautifulSoup 模块处理网页数据

搜索匹配的正则表达式,并使用 Beautiful Soup 和 findall 函数查找指定数据添加到列表 datalist 中,并返回列表数据。

```
1.#影片详情链接的规则
2. findLink = re.compile(r'<a href="(.*?)">') #创建正则表达式对象,表示规则(字符
3.#影片图片
4.findImgSrc = re.compile(r'<img.*src="(.*?)"',re.S) #re.S 让换行符包含在字符
5.#影片片名
6.findTitle = re.compile(r'<span class="title">(.*)</span>')
7.#影片评分
8.findRating = re.compile(r'<span class="rating num" property="v:average">(.*)</
   span>')
9. #找到评价人数
10. findJudge = re.compile(r'<span>(\d*)人评价</span>')
11. #找到概况
12. findIng = re.compile(r'<span class="ing">(.*)</span>')
13. #找到影片的相关内容
14. findBd = re.compile(r'(.*?)',re.S)
15.
16.
17. #爬取网页函数
18. def getData(baseurl):
19.
      datalist = []
                               #调用获取页面信息的函数,10次
20.
      for i in range(0,10):
21.
          url = baseurl + str(i*25)
22.
          html = askURL(url) #保存获取到的网页源码
23.
24.
           # 2.逐一解析数据
25.
          soup = BeautifulSoup(html, "html.parser")
          for item in soup.find_all('div',class_="item"):
                                                       #查找符合要求的字
26.
   符串,形成列表
                         #测试: 查看电影 item 全部信息
27.
             #print(item)
             data = [] #保存一部电影的所有信息
28.
29.
             item = str(item)
30.
31.
             #影片详情的链接
```

```
#re 库用来通过正则表达式查
32.
               link = re.findall(findLink,item)[0]
   找指定的字符串
33.
               data.append(link)
                                                     #添加链接
34.
35.
               imgSrc = re.findall(findImgSrc,item)[0]
36.
               data.append(imgSrc)
                                                     #添加图片
37.
38.
               titles = re.findall(findTitle,item)
                                                     #片名可能只有一个中文名,没
   有外国名
39.
               if(len(titles) == 2):
40.
                   ctitle = titles[0]
                                                     #添加中文名
41.
                   data.append(ctitle)
                   otitle = titles[1].replace("/","")
42.
                                                     #去掉无关的符号
                   data.append(otitle)
43.
                                                     #添加外国名
44.
               else:
45.
                   data.append(titles[0])
46.
                   data.append(' ')
                                          #外国名字留空
47.
               rating = re.findall(findRating,item)[0]
48.
49.
               data.append(rating)
                                                        #添加评分
50.
               judgeNum = re.findall(findJudge,item)[0]
51.
52.
               data.append(judgeNum)
                                                         #提加评价人数
53.
54.
               inq = re.findall(findInq,item)
55.
               if len(inq) != 0:
56.
                   inq = inq[0].replace(".","")
                                                  #去掉句号
                                                  # 添加概述
57.
                   data.append(inq)
58.
               else:
59.
                   data.append(" ")
                                                  #留空
60.
               bd = re.findall(findBd,item)[0]
61.
               bd = re.sub('<br(\s+)?/>(\s+)?'," ",bd) #去掉<br/>
62.
63.
               bd = re.sub('/'," ",bd)
                                          #替换/
64.
               data.append(bd.strip())
                                          #去掉前后的空格
65.
               print(data)
                                          #把处理好的一部电影信息放入 datalist
66.
               datalist.append(data)
67.
68.
       return datalist
```

将列表中存储的**数据导入**到 excel 表中,使用 xlwt 模块。

```
1.# 保存数据到 excel 表中
2.def saveData(datalist,savepath):
3.
      print("save....")
4.
      book = xlwt.Workbook(encoding="utf-8",style_compression=0) #创建workbook
   对象
5.
      sheet = book.add_sheet('豆瓣电影 Top250',cell_overwrite_ok=True)
                                                                     #创建工
   作表
     col = ("电影详情链接","图片链接","影片中文名","影片外国名","评分","评价数","概
6.
   况","相关信息")
      for i in range(0,8):
8.
         sheet.write(0,i,col[i]) #列名
9.
      for i in range(0,250):
10.
           print("第%d 条" %(i+1))
11.
           data = datalist[i]
12.
           for j in range(0,8):
13.
               sheet.write(i+1,j,data[j])
                                             #数据
14.
15.
       book.save(savepath)
                               #保存
1.def main():
2.
      baseurl = "https://movie.douban.com/top250?start="
3.
      #1.爬取网页
4.
      datalist = getData(baseurl)
```

主函数调用

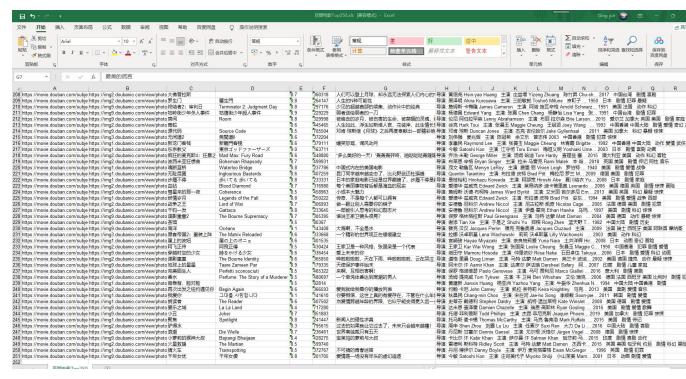
```
5.
6.
      savepath = "豆瓣电影 Top250.xls"
7.
      # dbpath = "movie.db"
8.
      #3.保存数据
9.
      saveData(datalist,savepath)
10.
11. if __name__ == "__main__":
                                      #当程序执行时
12.#调用函数
13.
       main()
14.
       askURL("https://movie.douban.com/top250?start=")
15.
       #init db("movietest.db")
       print("爬取完毕!")
16.
```

六、实验数据及处理结果

(请根据实际的数据来填写)



Excel 表格数据



七、思考讨论题或体会或对改进实验的建议

(请根据实际的数据来填写)

八、参考资料

- [1] [美] 阿曼多·凡丹戈(Armando Fandango) 著, 韩波 译. Python 数据分析(第 2 版). 人民邮电出版社.2018.6
- [2] 嵩天,礼欣,黄天羽 著.Python 语言程序设计基础(第2版). 高等教育出版社.2017.2